교과목명	인공지능학습데이터전처리				
과제번호	4	학 번	2601110288	이 름	박수용

NCS코드	능력단위명	능력단위요소	평가
2001070304_23_V2	인공지능데이터전처리	인공지능데이터정제하기 인공지능데이터통합하기 인공지능데이터 변환하기 인공지능데이터 축소하기 인공지능데이터 라벨링하기 인공지능데이터 비식별화하기	

요구사항

가스환경 데이터를 이용하여 미래를 예측하는 모델을 학습하시오.
3초, 30초 후를 예측하고 결과를 비교하시오.
단, Dense와 CNN레이어만 사용하고, 데이터 전처리는 각 컬럼별 0~1로 스케일링
전처리과 학습데이터 구축, 모델구성의 방법과 이유 그리고 결과를 아래에 작성하시오.

평가문항(수행내용)

<가스환경 데이터의 3초 후와 30초 후 예측>

1. 실험 목적과 데이터 확인

이번 과제에서는 가스환경 데이터를 이용하여 3초 후와 30초 후의 센서값을 예측하였습니다. 같은 입력 데이터와 모델 구조를 사용하고 예측 시점만 다르게 설정하여, 예측 시간이 길어질 때 오차가 어떻게 달라지는지 비교하였습니다.

예측 대상은 Temp1, Press1, Temp2, Press2, Acc, Gas의 6개 센서입니다. 과거 센서값을 입력하면 해당 미래 시점의 센서값 6개를 한 번에 출력하도록 구성하였습니다.

데이터는 _Merged_Data 폴더의 CSV 파일 1,000개를 사용하였습니다. 각 파일은 헤더 없이 3,000행과 7개 열로 구성되어 있었습니다. 이 중 index는 행 순서를 확인하는 데 사용하고, 모델에는 나머지 센서값 6개만 입력하였습니다.

PNG 파일은 데이터 형태와 시간 간격을 확인하는 데 참고하였습니다. 통합 CSV와 내용이 중복되는 개별 센서 CSV는 추가로 사용하지 않았습니다.

2. 전처리 방법과 이유

CSV 파일의 첫 번째 행에도 실제 센서값이 들어 있으므로, 첫 행을 열 이름으로 처리하지 않고 데이터로 읽었습니다. 전체 파일을 확인한 결과 NaN과 무한대 값은 없었습니다. 센서값이 0인 경우도 있었지만, 0이라는 이유만으로 결측값으로 처리하거나 삭제하지 않았습니다.

센서마다 값의 범위가 다르기 때문에 각 열에 최소–최대 정규화를 적용하였습니다. 예를 들어 Gas는 다른 센서보다 값의 범위가 커서, 원래 값을 그대로 사용하면 학습 오차에 더 큰 영향을 줄 수 있습니다. 따라서 각 센서값을 0~1 범위로 변환하여 학습하였습니다.

정규화 기준을 구하기 전에 파일을 학습·검증·시험 데이터로 나누었습니다. 이후 학습 파일 700개에서만 센서별 최솟값과 최댓값을 구하고, 검증·시험 데이터에도 같은 기준을 적용하였습니다. 시험 데이터의 정보가 전처리 기준에 반영되지 않도록 하기 위한 방법입니다.

사용한 변환식은 다음과 같습니다.

- 정규화한 값 = (원래 값 − 학습 데이터 최솟값) ÷ (학습 데이터 최댓값 − 학습 데이터 최솟값)

교과목명	인공지능학습데이터전처리				
과제번호	4	학 번	2601110288	이 름	박수용

평가문항(수행내용)

센서	학습 최솟값	학습 최댓값
Temp1	0	110
Press1	0	3.25
Temp2	0	110
Press2	0	3.25
Acc	0	0.1
Gas	0	1007

입력값과 정답에는 같은 정규화 기준을 사용하였습니다. 검증·시험 데이터도 모두 학습 데이터의 범위 안에 있었습니다.

코드에는 범위를 벗어난 값을 0~1로 제한하는 처리가 포함되어 있지만, 이번 데이터에서는 이 처리로 바뀐 값이 없었습니다. 센서별 오차를 구할 때는 예측값을 원래 범위로 되돌린 후 실제값과 비교하였습니다.

3. 학습 데이터 구성

원본 그래프의 가로축에 Timestamp(100 ms)라고 표시되어 있어, 한 행의 간격을 0.1초로 보고 데이터를 구성하였습니다. 이 기준에서 3초 후는 30행 뒤이고, 30초 후는 300행 뒤입니다.

모델 입력에는 연속된 관측값 100개를 사용하였습니다. 관측값은 100개이지만 첫 번째 관측값과 마지막 관측값 사이의 시간은 9.9초입니다.

입력 시작 행을 s라고 하면 입력 구간은 s행부터 s+99행까지입니다. 정답은 입력의 마지막 시점을 기준으로 정하였습니다. 따라서 3초 후 정답은 s+129행, 30초 후 정답은 s+399행입니다.

입력 구간	3초 후 정답	30초 후 정답
0~99행	129행	399행
2600~2699행	2729행	2999행

두 모델을 같은 입력 조건에서 비교하기 위해, 30초 후 정답까지 존재하는 시작점인 0~2600행을 공통으로 사용하였습니다. 입력 시작점은 5행씩 이동하였습니다. 여기서 5행은 학습 샘플을 만드는 간격이며, 예측 간격인 30행과 300행은 그대로 유지하였습니다.

파일 하나에서 만들어지는 샘플 수는 다음과 같습니다.

파일당 샘플 수 = (3000 − 100 − 300) ÷ 5 + 1 = 521개

데이터를 나눌 때는 CSV 경로를 정렬한 뒤 시드 42로 파일 순서를 섞고, 파일 단위로 700개·150개·150개를 배정하였습니다.

구분	파일 수	원본 행 수	윈도우 수
학습	700	2,100,000	364,700
검증	150	450,000	78,150
시험	150	450,000	78,150

교과목명	인공지능학습데이터전처리				
과제번호	4	학 번	2601110288	이 름	박수용

평가문항(수행내용)

연속된 입력 구간을 먼저 만든 뒤 무작위로 나누면, 같은 파일의 겹치는 구간이 학습과 시험에 동시에 포함될 수 있습니다. 이를 피하기 위해 파일을 먼저 나누고 각 파일 안에서 샘플을 만들었습니다. 서로 다른 파일을 이어 붙여 입력이나 정답을 만들지는 않았습니다.

입력 형태는 (배치 크기, 100, 6)이며, 정답과 모델 출력 형태는 (배치 크기, 1, 6)입니다. 출력의 1은 예측할 미래 시점 하나를, 6은 센서 6개를 의미합니다.

데이터 구성 후에는 간단한 예제 데이터와 실제 데이터에서 정답 위치와 샘플 수가 맞는지 확인하였습니다. 또한 메모리 사용량을 줄이기 위해 모든 입력 구간을 미리 복사하지 않고, 배치마다 필요한 구간을 가져오도록 하였습니다.

4. 모델 구성과 학습 조건

모델은 TensorFlow로 구현하였으며, 과제 조건에 맞춰 Conv1D 3개와 Dense 2개로 구성하였습니다.

Conv1D는 시간 순서에 따라 센서값이 변하는 특징을 학습하기 위해 사용하였습니다.

앞의 두 합성곱층에서 시간 방향의 길이를 줄이고, 세 번째 합성곱층에서 남은 구간을 하나로 모으도록 구성하였습니다.

아래 표에서 **B**는 **배치 크기**입니다.

레이어	주요 설정	출력 shape
Conv1D	32개 필터, 커널 5, stride 2, same, ReLU	(B, 50, 32)
Conv1D	32개 필터, 커널 5, stride 2, same, ReLU	(B, 25, 32)
Conv1D	32개 필터, 커널 25, valid, ReLU	(B, 1, 32)
Dense	32개 노드, ReLU	(B, 1, 32)
Dense	6개 노드, sigmoid	(B, 1, 6)

마지막 합성곱층의 커널 크기를 25로 설정하여 시간 방향의 길이가 1이 되도록 하였습니다. 이 방법으로 별도의 Pooling이나 Flatten 레이어 없이 Dense에 연결하였습니다.

마지막 Dense의 노드 수는 예측할 센서 수에 맞춰 6개로 설정하였습니다. 출력에는 sigmoid를 적용하여 예측값이 0~1 범위에 들어오도록 하였습니다. 전체 학습 파라미터 수는 33,030개입니다.

3초 모델과 30초 모델은 각각 따로 학습하였습니다. 두 모델의 비교 조건을 맞추기 위해 파일 분할, 입력 구간, 정규화 기준, 모델 구조와 초기 가중치를 같게 설정하였습니다. 예측할 정답 시점만 다르게 하였습니다.

항목	설정 내용
최적화 방법	Adam
학습률 (Learning Rate)	0.001
배치 크기 (Batch Size)	512
손실 함수 (Loss Function)	정규화한 센서 6개의 평균제곱오차 (MSE)
학습 횟수 (Epochs)	각 모델 20 Epoch
가중치 선택 기준	검증 MSE가 가장 낮은 Epoch
난수 시드 (Random Seed)	42

교과목명	인공지능학습데이터전처리				
과제번호	4	학 번	2601110288	이 름	박수용

평가문항(수행내용)

두 모델 모두 20 epoch까지 학습한 뒤, 검증 오차가 가장 낮았던 가중치로 시험하였습니다. 시험 데이터는 학습이나 가중치 선택에 사용하지 않았습니다.

5. 학습 결과와 전체 오차 비교

모델	학습 횟수	선택 epoch	최소 검증 MSE
3초 후	20 epoch	20	0.00067023
30초 후	20 epoch	18	0.00261739

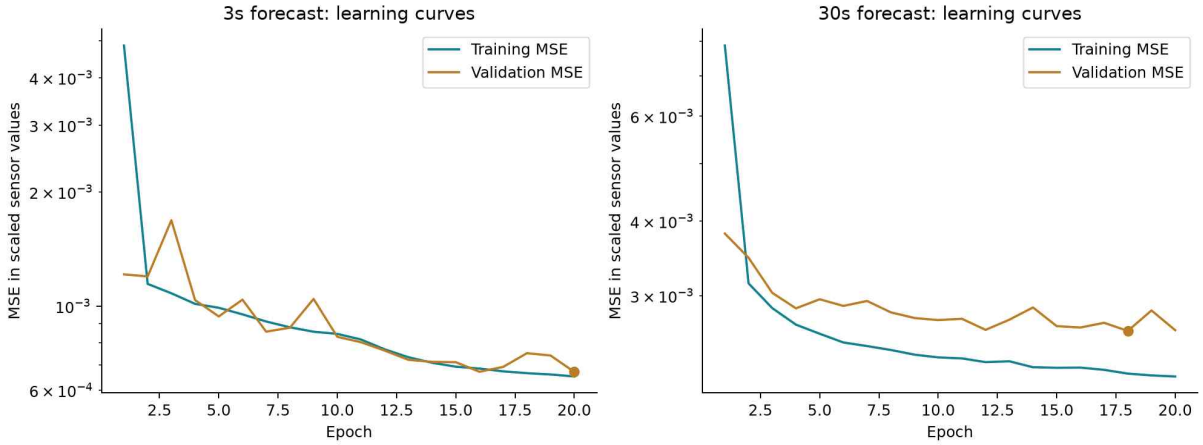


그림 1. 3초 및 30초 모델의 학습·검증 MSE

두 모델 모두 학습 초기에 오차가 크게 줄었습니다. 3초 모델은 20번째 epoch에서 검증 오차가 가장 낮았고, 30초 모델은 18번째 epoch에서 가장 낮았습니다.

30초 모델은 학습 오차가 줄어드는 동안 검증 오차가 비슷한 수준에서 오르내렸습니다. 따라서 학습을 더 진행하는 것만으로 검증 성능이 계속 좋아지지는 않았습니다.

시험에는 학습에 사용하지 않은 파일 150개를 사용하였습니다. 두 모델 모두 같은 입력 샘플 78,150개로 평가하였습니다.

비교 대상으로는 마지막 입력값을 미래 예측값으로 그대로 사용하는 '단순 유지 예측'을 사용하였습니다. 학습 모델이 현재 값을 그대로 사용하는 방법보다 얼마나 나은지 확인하기 위해서입니다.

센서마다 값의 범위가 다르므로 전체 성능은 정규화한 오차로 비교하였습니다. MAE는 오차의 절댓값을 평균한 값이며, RMSE는 오차를 제곱하여 평균한 뒤 제곱근을 구한 값입니다. 두 지표 모두 작을수록 예측 오차가 작습니다.

예측 시점	방법	정규화 MAE	정규화 RMSE
3s	CNN + Dense	0.019184	0.025724
3s	단순 유지	0.019207	0.026914
30s	CNN + Dense	0.036486	0.049473
30s	단순 유지	0.091982	0.114734

교과목명	인공지능학습데이터전처리				
과제번호	4	학 번	2601110288	이 름	박수용

평가문항(수행내용)

CNN 모델의 정규화 RMSE는 3초 예측에서 0.025724, 30초 예측에서 0.049473으로 나타났습니다. 30초 예측의 오차가 약 1.92배 컸습니다.

단순 유지 예측과 비교하면 CNN의 RMSE는 3초 예측에서 약 4.42%, 30초 예측에서 약 56.88% 낮았습니다. 즉, 3초 예측은 오차 자체가 작았지만 단순 유지 방법과의 차이도 작았습니다. 반면 30초 예측은 오차가 더 컸으나, 단순 유지 방법보다 개선된 정도는 더 컸습니다.

6. 센서별 결과 비교

센서별 RMSE는 예측값을 원래 범위로 되돌린 후 계산하였습니다. 센서마다 단위와 범위가 다르므로, 서로 다른 센서의 숫자 크기를 직접 비교하지 않고 같은 센서 안에서 결과를 비교하였습니다.

센서	CNN 3초	유지 3초	CNN 30초	유지 30초
Temp1	2.78987	2.97712	5.32599	12.7877
Press1	0.0881181	0.0881445	0.161649	0.381932
Temp2	2.79124	3.03999	5.66529	12.6339
Press2	0.0785685	0.0861179	0.158545	0.371956
Acc	0.00272329	0.00265632	0.00490479	0.011353
Gas	25.1161	26.7698	49.6333	112.496

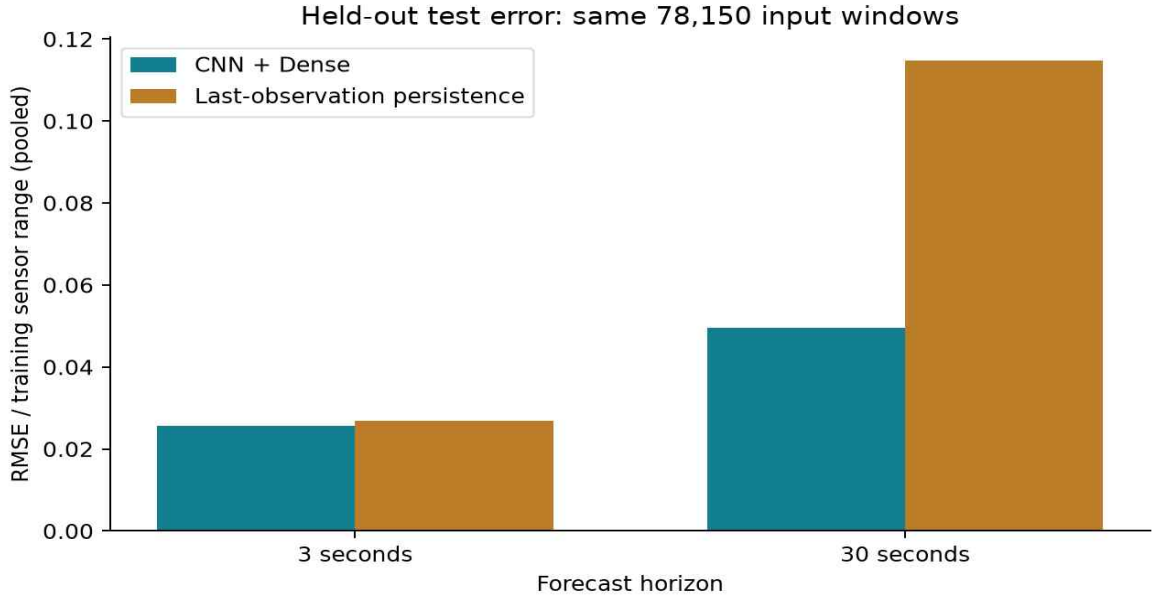


그림 2. 동일 시험 입력에서의 정규화 RMSE 비교

3초 예측에서는 단순 유지 방법도 오차가 작았습니다. Press1은 두 방법의 결과가 거의 같았고, Acc는 CNN의 RMSE가 단순 유지보다 조금 더 컸습니다. 전체 오차가 줄었더라도 모든 센서에서 성능이 좋아진 것은 아니었습니다.

30초 예측에서는 센서 6개 모두 CNN의 RMSE가 단순 유지보다 낮았습니다. Gas의 경우 단순 유지의 RMSE는 112.496이었고, CNN은 49.6333으로 나타났습니다.

다만 CNN 모델끼리 비교하면 모든 센서에서 30초 예측 오차가 3초 예측 오차보다 컸습니다. 예측 시간이 길어질수록 오차는 증가하였지만, 현재 값을 그대로 유지하는 방법보다는 학습 모델이 미래 변화를 더 잘 예측하였습니다.

교과목명	인공지능학습데이터전처리				
과제번호	4	학 번	2601110288	이 름	박수용

평가문항(수행내용)

7. 실제값과 예측값 비교

예측 결과를 그래프로 확인하기 위해, 정렬된 시험 파일 목록의 첫 번째 파일인 _Merged_Data_data_set_00001.csv를 사용하였습니다. 해당 파일에서 만든 입력 샘플 521개를 모두 표시하였습니다.

그래프의 가로축은 입력 시점이 아닌 정답 시점이며, 한 행을 0.1초로 보는 기준을 적용하였습니다.

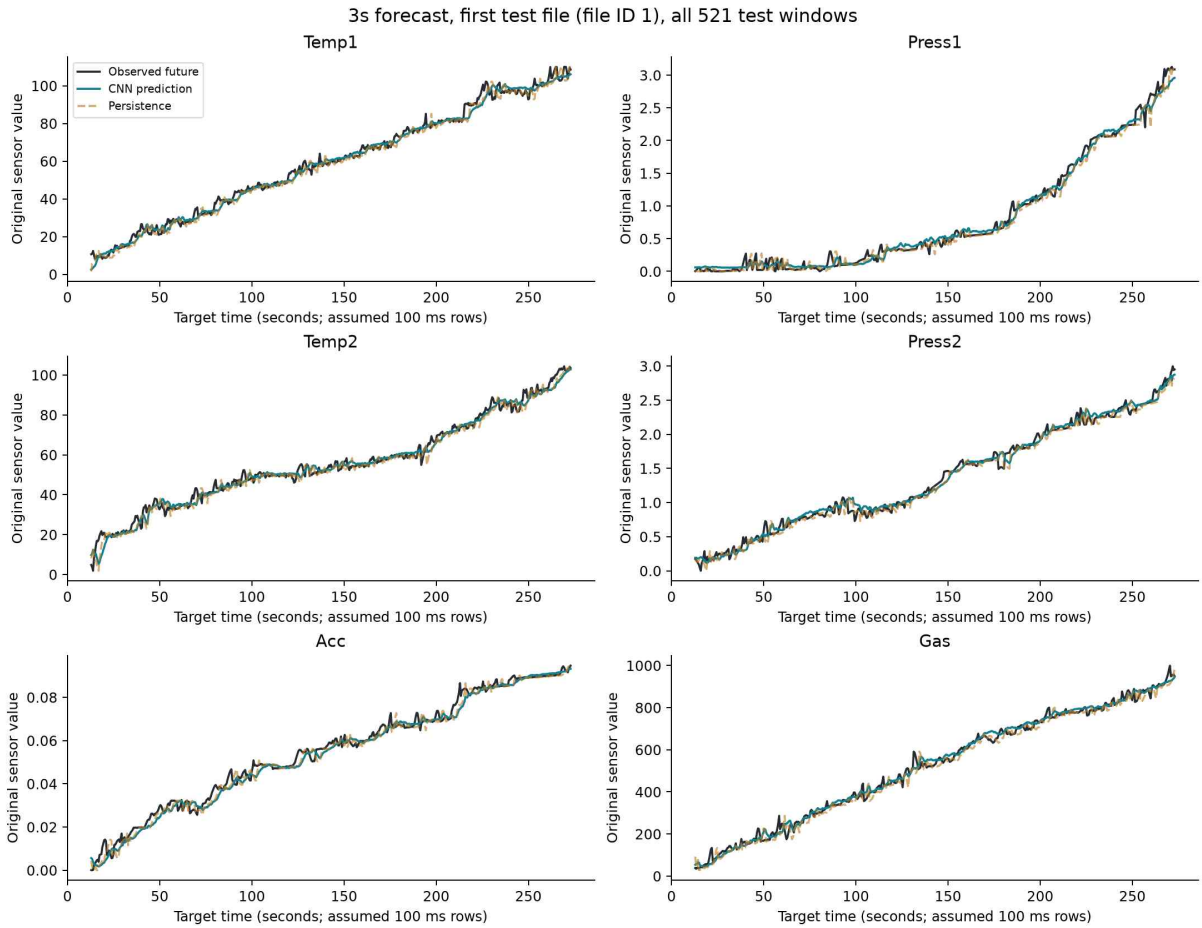


그림 3. 첫 시험 파일의 3초 후 실제값·CNN 예측·단순 유지 예측

3초 후 예측에서는 CNN 예측값이 실제값의 전체적인 변화를 따라가는 모습을 보였습니다. 단순 유지 예측도 실제값과 가까운 구간이 많았습니다.

이는 3초 동안 센서값이 크게 바뀌지 않는 구간에서는 마지막 값을 그대로 사용하는 방법도 오차가 작을 수 있다는 것을 보여줍니다. 전체 시험 결과에서도 두 방법의 성능 차이가 크지 않았습니다.

이 그래프는 시험 파일 한 개의 결과이며, 앞의 오차 표는 시험 파일 150개 전체에서 계산한 결과입니다. 또한 입력 구간이 서로 겹치므로, 샘플 78,150개를 모두 서로 독립된 실험으로 볼 수는 없습니다.

교과목명	인공지능학습데이터전처리				
과제번호	4	학 번	2601110288	이 름	박수용

평가문항(수행내용)

8. 30초 예측 결과와 정리

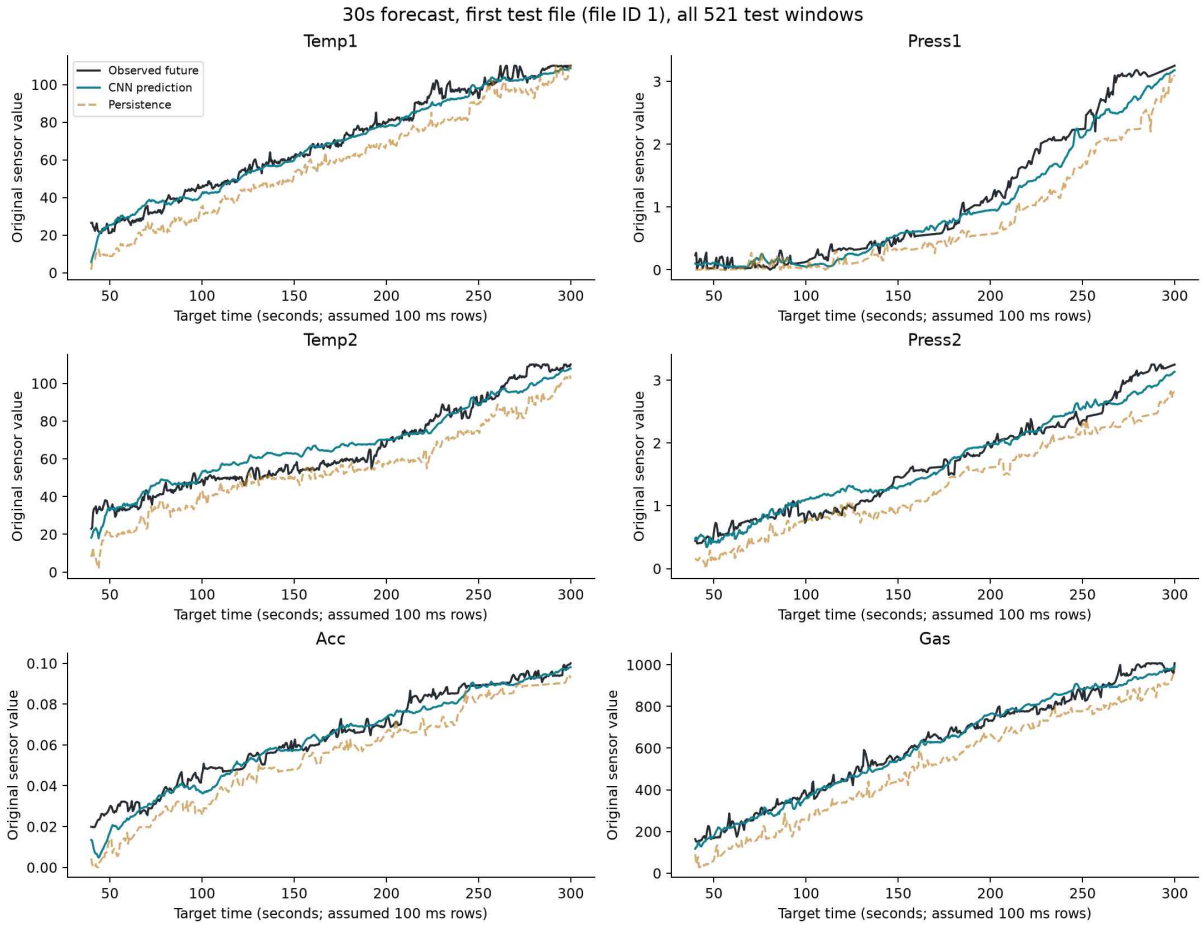


그림 4. 같은 시험 파일의 30초 후 실제값·CNN 예측·단순 유지 예측

30초 후 예측 그래프에서는 단순 유지 예측과 실제값 사이의 차이가 3초 예측보다 크게 나타났습니다. 예시 파일에 센서값이 전반적으로 상승하는 구간이 많아, 30초 전 값을 그대로 사용하는 방법은 실제값보다 낮게 예측하는 경우가 많았습니다.

CNN은 이 차이를 줄였지만 실제값의 변화를 모두 맞추지는 못하였습니다. 특히 Temp2와 Press1 등에서는 실제값보다 높거나 낮게 예측하는 구간이 남아 있었습니다.

이번 실험에서는 3초 후 예측이 30초 후 예측보다 오차가 작았습니다. 반면 단순 유지 방법과 비교했을 때의 개선 폭은 30초 후 예측에서 더 컸습니다. 따라서 예측 오차의 크기와 함께, 단순한 예측 방법보다 얼마나 나아졌는지도 확인할 필요가 있었습니다.

이번 결과는 입력 관측값 100개, 시드 42, 한 가지 CNN 구조를 사용한 결과입니다. 입력 길이나 모델 구조를 바꾸었을 때도 같은 결과가 나오는지는 추가 실험이 필요합니다. 파일 단위로 데이터를 나누고 동일한 내용의 중복도 검사하였지만, 서로 다른 파일이 같은 실험 조건에서 만들어졌는지는 확인하지 못하였습니다.

과제를 진행하면서 모델 구성뿐 아니라 전처리와 정답 위치를 정확히 설정하는 과정이 중요하다는 점을 확인하였습니다. 특히 학습 데이터에서만 정규화 기준을 구하고, 입력의 마지막 시점을 기준으로 3초 후와 30초 후 정답을 정해야 두 결과를 같은 조건에서 비교할 수 있었습니다.