

교과목명	인공지능학습데이터전처리																
과제번호	1	학 번	2601110288	이 름	박수용												
NCS코드		능력단위명	능력단위요소		평가												
2001070304_23_V2		인공지능데이터전처리	인공지능데이터정제하기 인공지능데이터통합하기 인공지능데이터 변환하기 인공지능데이터 축소하기 인공지능데이터 라벨링하기 인공지능데이터 비식별화하기														
요구사항																	
영화리뷰 분류모델 학습을 위해 필요한 학습데이터의 전처리와 Loss Function, Activation Function 등 하이퍼파라미터를 선택하여 구성하시오. 단, 모델의 출력은 2개 Unit / 수행내용에는 이유 또는 근거를 제시하여야 함. PDF로 제출																	
평가문항(수행내용)																	
1. 실습 목적 IMDB 영화 리뷰를 긍정과 부정으로 분류하기 위해 입력 데이터의 길이를 맞추고, 정답의 표현 방식에 맞는 손실함수와 활성화함수를 구성하였습니다. 과제에서 출력층을 2개 Unit으로 지정하였으므로, 수업 예제의 출력층을 Dense(2, activation='softmax')로 변경하였습니다. 정수 레이블을 사용하는 Review.py와 원-핫 레이블을 사용하는 Review_OHV.py를 비교하고 학습 결과를 확인하였습니다. 2. 데이터 구성 및 전처리 <table><tr><td>항목</td><td>설정 및 선택 이유</td></tr><tr><td>데이터와 정답</td><td>IMDB 영화 리뷰를 사용하였습니다. 정답은 부정 0, 긍정 1로 구분됩니다.</td></tr><tr><td>어휘 범위</td><td>num_words=10000으로 단어 인덱스 범위를 제한하였습니다. 자주 등장하는 단어 중심으로 입력을 구성하여 어휘 규모를 줄이기 위한 설정입니다.</td></tr><tr><td>입력 형태</td><td>리뷰는 이미 단어가 정수 인덱스로 변환된 상태로 불러옵니다. 단어 복원 함수는 내용을 확인하는 용도이며 학습 입력을 다시 만드는 과정은 아닙니다.</td></tr><tr><td>리뷰 길이</td><td>maxlen=256으로 길이를 통일하였습니다. 짧은 리뷰는 뒤에 0을 채우고, 긴 리뷰는 truncating 기본값인 pre에 따라 앞부분을 잘라 뒤쪽 256개를 사용합니다.</td></tr><tr><td>특수 인덱스</td><td>0은 패딩, 1은 리뷰 시작, 2는 사전 범위 밖 단어, 3은 미사용 인덱스로 설정하였습니다.</td></tr></table> 데이터 로더의 기본 구성은 훈련용 25,000개와 테스트용 25,000개입니다. 코드에서는 훈련용의 앞 10,000개를 검증에, 나머지 15,000개를 실제 학습에 사용합니다. 검증 데이터는 학습 상태를 확인하는 데 사용하고 테스트 데이터는 학습 후 최종 평가에 사용하도록 분리하였습니다. 현재 코드는 원문 중복 제거, 결측값 검사, 개인정보 비식별화 등을 별도로 수행하지 않습니다. 이번 실습에서 직접 수행한 전처리는 어휘 범위 제한, 길이 통일, 검증 데이터 분리 및 정답 형식 변환입니다. 입력 단어를 원-핫 벡터로 변환하지는 않았습니다.						항목	설정 및 선택 이유	데이터와 정답	IMDB 영화 리뷰를 사용하였습니다. 정답은 부정 0, 긍정 1로 구분됩니다.	어휘 범위	num_words=10000으로 단어 인덱스 범위를 제한하였습니다. 자주 등장하는 단어 중심으로 입력을 구성하여 어휘 규모를 줄이기 위한 설정입니다.	입력 형태	리뷰는 이미 단어가 정수 인덱스로 변환된 상태로 불러옵니다. 단어 복원 함수는 내용을 확인하는 용도이며 학습 입력을 다시 만드는 과정은 아닙니다.	리뷰 길이	maxlen=256으로 길이를 통일하였습니다. 짧은 리뷰는 뒤에 0을 채우고, 긴 리뷰는 truncating 기본값인 pre에 따라 앞부분을 잘라 뒤쪽 256개를 사용합니다.	특수 인덱스	0은 패딩, 1은 리뷰 시작, 2는 사전 범위 밖 단어, 3은 미사용 인덱스로 설정하였습니다.
항목	설정 및 선택 이유																
데이터와 정답	IMDB 영화 리뷰를 사용하였습니다. 정답은 부정 0, 긍정 1로 구분됩니다.																
어휘 범위	num_words=10000으로 단어 인덱스 범위를 제한하였습니다. 자주 등장하는 단어 중심으로 입력을 구성하여 어휘 규모를 줄이기 위한 설정입니다.																
입력 형태	리뷰는 이미 단어가 정수 인덱스로 변환된 상태로 불러옵니다. 단어 복원 함수는 내용을 확인하는 용도이며 학습 입력을 다시 만드는 과정은 아닙니다.																
리뷰 길이	maxlen=256으로 길이를 통일하였습니다. 짧은 리뷰는 뒤에 0을 채우고, 긴 리뷰는 truncating 기본값인 pre에 따라 앞부분을 잘라 뒤쪽 256개를 사용합니다.																
특수 인덱스	0은 패딩, 1은 리뷰 시작, 2는 사전 범위 밖 단어, 3은 미사용 인덱스로 설정하였습니다.																

교과목명	인공지능학습데이터전처리				
과제번호	1	학 번	2601110288	이 름	박수용

평가문항(수행내용)

3. 모델 구조와 학습 설정

구성	설정	선택 이유
Embedding	입력 인덱스 범위 10,000개 / 벡터 16차원	단어 인덱스마다 학습 가능한 16차원 벡터를 사용하여 단어의 특징을 표현하였습니다. 벡터 크기는 수업 예제의 설정을 유지하였습니다.
GlobalAveragePooling1D	단어 벡터 평균	리뷰의 단어 벡터를 평균하여 길이에 관계없이 16차원 특징으로 정리합니다.
은닉층	Dense(16), ReLU	리뷰 특징을 조합합니다. ReLU는 음수 입력을 0으로 만들고 양수 입력은 유지하여 비선형 관계를 학습하게 합니다.
출력층	Dense(2), Softmax	부정과 긍정의 두 출력을 만들고, 두 값의 합이 1이 되도록 변환합니다. 출력 2개 조건을 충족합니다.
최적화 / 지표	Adam / accuracy	Adam으로 가중치를 갱신하며, 정확하게 정답을 맞힌 비율을 확인합니다. 학습률은 별도로 지정하지 않았습니다.
학습 횟수 / 배치	40회 / 512개	수업 예제의 설정을 유지하여 학습 흐름을 비교하였습니다. 최적의 값이라고 확정한 설정은 아닙니다.

현재 Embedding에는 mask_zero=True가 지정되어 있지 않습니다. 따라서 패딩 인덱스 0의 벡터도 평균 계산에 포함됩니다. 또한 단어 벡터를 평균하는 구조이므로 문장 속 단어 순서를 충분히 반영하기 어렵다는 한계가 있습니다.

4. 정답 형식과 손실함수 선택

구분	Review.py	Review_OHV.py
정답 형식	부정 0 / 긍정 1	부정 [1, 0] / 긍정 [0, 1]
정답 변환	정수 레이블 그대로 사용	to_categorical(..., num_classes=2)
손실함수	sparse_categorical_crossentropy	categorical_crossentropy
출력층	2개 Unit, Softmax	2개 Unit, Softmax

정수 정답에는 sparse_categorical_crossentropy를, 원-핫 정답에는 categorical_crossentropy를 선택하였습니다. 두 함수는 정답의 표현 방식이 다르지만 같은 분류 문제의 오차를 계산합니다. 동일한 예측과 정답을 사용한다면 이론적으로 같은 교차 엔트로피 값을 계산하므로, 원-핫 변환 자체가 성능을 높인다고 볼 수는 없습니다.

핵심 코드 / 설명 / 역할

코드	설명	역할
pad_sequences(..., padding='post', maxlen=256)	리뷰 길이를 256으로 통일	입력 길이 정리
Dense(2, activation='softmax')	긍정·부정 두 값 출력	출력 조건 충족
to_categorical(labels, num_classes=2)	정수 정답을 원-핫으로 변환	정답 표현 변경

교과목명	인공지능학습데이터전처리				
과제번호	1	학 번	2601110288	이 름	박수용

평가문항(수행내용)

5. Review.py 실행 결과

정수 레이블과 sparse_categorical_crossentropy를 적용한 결과입니다. 아래 수치는 첨부 그래프를 눈으로 읽은 대략적인 값이며, 정확한 학습 로그 수치는 아닙니다.




그림 1. Review.py의 훈련·검증 손실




그림 2. Review.py의 훈련·검증 정확도

교과목명	인공지능학습데이터전처리				
과제번호	1	학 번	2601110288	이 름	박수용

평가문항(수행내용)

학습 초반에는 훈련 손실과 검증 손실이 함께 감소하였습니다. 이후 훈련 손실은 계속 줄어 마지막에 약 0.11에 도달하지만, 검증 손실은 약 0.28~0.30 부근에서 크게 개선되지 않았습니다. 후반에는 검증 손실이 다소 높아지는 구간도 나타났습니다.

훈련 정확도는 마지막에 약 96%까지 높아졌습니다. 검증 정확도는 후반에 약 88~89% 수준에서 머물다가 마지막에는 약 86~87%로 낮아졌습니다. 훈련 데이터에서는 성능이 계속 좋아지지만 검증 데이터에서는 개선이 제한되는 과적합 경향을 확인하였습니다.

6. Review_OHV.py 실행 결과

정답을 원-핫 벡터로 변환하고 categorical_crossentropy를 적용한 결과입니다. 입력 전처리와 모델 구조, 학습 횟수 및 배치 크기는 Review.py와 같습니다.




그림 3. Review_OHV.py의 훈련·검증 손실

교과목명	인공지능학습데이터전처리				
과제번호	1	학 번	2601110288	이 름	박수용

평가문항(수행내용)




그림 4. Review_OHV.py의 훈련·검증 정확도

훈련 손실은 마지막에 약 0.09까지 감소하였습니다. 검증 손실은 20회 전후에 약 0.28 수준까지 낮아진 뒤, 후반에는 증가하여 마지막에 약 0.32를 보였습니다. 손실 그래프의 최저점에 대한 정확한 학습 횟수는 원본 로그를 확인해야 합니다.

훈련 정확도는 마지막에 약 97%까지 높아졌지만 검증 정확도는 약 88~89% 수준에서 정체되었고 마지막에는 약 88%였습니다. 이 결과에서도 훈련과 검증의 차이가 벌어져 과적합 경향이 나타났습니다. 코드에는 첫 테스트 리뷰의 예측 확률, 원-핫 예측 결과, 실제 정답을 출력하는 부분이 있으나, 첨부 이미지에는 출력값이 없어 일치 여부를 판단하지 않았습니다.

7. 두 결과 비교 및 개선 방향

비교 항목	Review.py	Review_OHV.py
마지막 훈련 손실	약 0.11	약 0.09
마지막 검증 손실	약 0.30	약 0.32
마지막 훈련 정확도	약 96%	약 97%
마지막 검증 정확도	약 86~87%	약 88%
공통 관찰	학습 후반 과적합 경향	학습 후반 과적합 경향

교과목명	인공지능학습데이터전처리				
과제번호	1	학 번	2601110288	이 름	박수용
평가문항(수행내용)					
표의 수치는 첨부 그래프에서 읽은 근삿값입니다. 검증 정확도는 테스트 정확도와 다르며, 두 코드의 <code>model.evaluate()</code> 출력값은 제공된 이미지에서 확인할 수 없습니다. 원-핫 버전은 마지막 검증 정확도가 조금 높게 보이지만 검증 손실은 더 높게 나타났습니다. 정확도는 정답을 맞혔는지를, 손실은 예측 확률이 정답과 얼마나 어긋났는지를 반영하므로 두 지표가 항상 같은 방향으로 움직이는 것은 아닙니다. 두 파일 모두 난수 시드를 고정하지 않았습니다. 따라서 관찰된 차이가 레이블 변환 때문인지, 초기 가중치와 학습 순서의 차이 때문인지 이번 결과만으로 구분하기 어렵습니다. 성능을 비교하려면 초기 조건을 맞추고 반복 실행한 결과를 확인해야 합니다. 우선 개선할 부분은 학습 종료 시점입니다. 검증 손실이 더 이상 줄어들지 않을 때 학습을 종료하는 <code>EarlyStopping</code>을 적용하고, 검증 손실이 가장 낮았던 가중치를 복원하는 방법을 검토할 수 있습니다. 필요하다면 <code>Dropout</code>이나 <code>L2</code> 규제도 비교할 수 있습니다. 다만 현재 두 코드에는 이러한 기능이 없으므로 이번 실습에서 적용한 방법으로 기록하지 않았습니다. 8. 실습 정리 이번 실습에서는 리뷰의 길이를 256으로 맞추고, 출력층을 2개 Unit과 Softmax로 구성하였습니다. 정수 레이블과 원-핫 레이블에 각각 맞는 손실함수를 선택하여, 정답 형식과 손실함수를 함께 확인해야 한다는 점을 이해하였습니다. 학습 결과에서는 훈련 정확도만으로 모델을 평가하면 부족하다는 점을 확인하였습니다. 40회 학습한 결과보다 중간 시점의 검증 손실이 더 낮게 나타났으므로, 이후에는 검증 결과를 기준으로 학습 횟수를 조정하고 최종 테스트 성능을 확인할 필요가 있습니다.					