교과목명	인공지능학습데이터전처리				
과제번호	2	학 번	2601110288	이 름	박수용

NCS코드	능력단위명	능력단위요소	평가
2001070304_23_V2	인공지능데이터전처리	인공지능데이터정제하기 인공지능데이터통합하기 인공지능데이터 변환하기 인공지능데이터 축소하기 인공지능데이터 라벨링하기 인공지능데이터 비식별화하기	

요구사항

영화리뷰 분류를 위한 모델을 구성했을 때 과적합 / 과소적합 방지를 위한 L2규제와 Dropout을 모두 사용하여 이전의 비교 모델과 함께 그래프로 표현하고 비교

평가문항(수행내용)

1. 실습 목적과 결과 요약

L2 규제와 Dropout을 함께 적용하였을 때 기본 모델보다 학습 후반의 검증 오차가 낮았습니다. 이번 실습에서는 IMDB 영화리뷰를 긍정과 부정으로 분류하는 모델을 만들고, 모델 크기와 규제 방법에 따라 결과가 어떻게 달라지는지 비교하였습니다. 기본 모델, 작은 모델, 큰 모델과 L2 단독, Dropout 단독, 동시 적용 모델을 학습하여 총 여섯 모델의 결과를 확인하였습니다.

2. 데이터 전처리와 학습 조건

IMDB 리뷰에서 사용하는 단어 번호의 범위를 1,000으로 제한하고, 각 리뷰를 길이 1,000의 벡터로 바꾸었습니다. 등장한 단어의 위치는 1, 나머지는 0으로 표시하는 Multi-Hot 방식입니다. 여러 위치가 동시에 1이 될 수 있으며 단어 순서와 반복 횟수는 보존하지 않습니다. 입력은 float32로 만들고, 정답은 0(부정)과 1(긍정)을 유지한 채 (25,000, 1) 형태로 바꾸어 출력 모양에 맞추었습니다.

항목	설정
훈련과 검증 데이터	훈련 25,000개 / 검증에 사용한 test_data 25,000개
사용 단어 수와 입력	1,000개 / Multi-Hot 벡터
출력과 손실 함수	1개 sigmoid / binary_crossentropy
최적화와 학습 조건	Adam / 100회 / 배치 크기 512
규제와 난수 설정	L2 계수 0.001 / Dropout 비율 0.5 / SEED 42

교과목명	인공지능학습데이터전처리				
과제번호	2	학 번	2601110288	이 름	박수용

평가문항(수행내용)

3. 비교 모델의 구성

입력과 출력, 최적화 방법을 같게 두고 은닉층 크기와 규제 설정을 바꾸었습니다. 은닉층은 ReLU, 출력층은 sigmoid를 사용하였습니다. 출력은 긍정으로 예측하는 확률이며 정답이 0 또는 1이므로 binary_crossentropy를 손실 함수로 사용하였습니다.

모델	은닉층 구성	규제 설정
기본 모델	16 → 16	없음
작은 모델	4 → 4	없음
큰 모델	512 → 512	없음
L2 모델	16 → 16	두 은닉층에 L2 0.001
Dropout 모델	16 → 16	각 은닉층 뒤에 Dropout 0.5
L2와 Dropout 모델	16 → 16	두 은닉층에 L2 0.001 / 각 층 뒤 Dropout 0.5

3.1 과적합과 과소적합

과적합은 훈련 데이터에 지나치게 맞추어 학습한 상태로, 훈련 오차는 줄어도 검증 오차는 커질 수 있습니다. 과소적합은 필요한 특징을 충분히 학습하지 못한 상태입니다. 작은 모델, 부족한 학습, 지나친 규제가 원인일 수 있으며 훈련과 검증 성능이 모두 부족한지 확인해야 합니다.

L2는 가중치 제곱의 합에 계수를 곱한 벌점을 학습 손실에 더하여 큰 가중치를 억제합니다. Dropout은 훈련 중 층 출력의 일부를 무작위로 0으로 만들어 특정 뉴런에 대한 의존을 줄입니다. 두 방법은 주로 과적합을 줄이는 데 사용하며, 규제를 강하게 적용하면 오히려 과소적합이 생길 수 있습니다.

3.2 핵심 코드와 역할

코드	설명	역할
results[i, word_indices] = 1.0	리뷰에 등장한 단어의 위치를 1로 표시합니다.	입력 데이터를 Multi-Hot 벡터로 변환
metrics=["accuracy", "binary_crossentropy"]	분류 오차를 별도 지표로 기록합니다.	규제 벌점이 제외된 훈련·검증 곡선 비교
Dense(16, activation="relu", kernel_regularizer= keras.regularizers.l2(0.001)) Dropout(0.5)	동시 적용 모델에서 이 순서를 두 번 반복합니다.	한 모델의 두 은닉층에 L2와 Dropout을 함께 적용

L2 계수 0.001과 Dropout 비율 0.5는 교재의 설정을 사용한 값이며, 별도로 찾은 최적값은 아닙니다. 동시 적용 모델은 두 은닉층에 두 방법을 함께 적용하고 출력층에는 규제를 넣지 않았습니다.

그래프는 binary_crossentropy와 val_binary_crossentropy를 사용하며 값이 낮을수록 분류 오차가 작습니다. L2 모델의 전체 loss에는 규제 벌점이 포함되므로, 벌점을 제외한 이 지표로 모델을 비교하였습니다.

교과목명	인공지능학습데이터전처리				
과제번호	2	학 번	2601110288	이 름	박수용
평가문항(수행내용)					

4. 모델 크기에 따른 결과

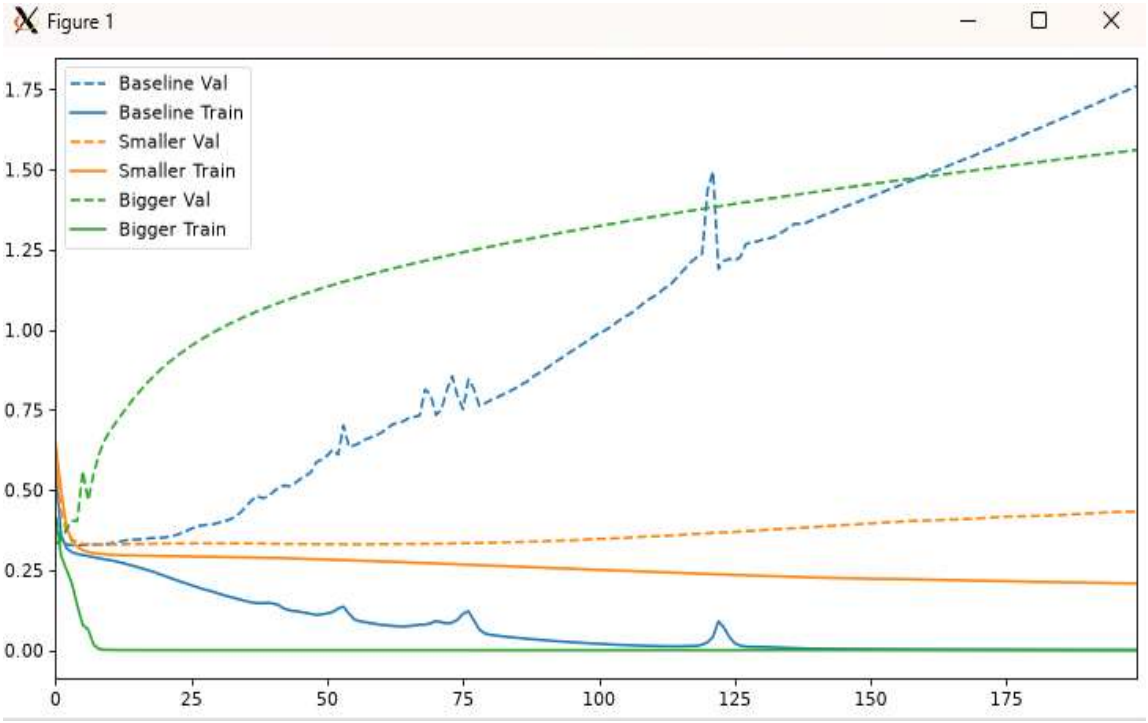


그림 1 기본 모델과 작은 모델 및 큰 모델의 기존 비교 결과

같은 색의 실선은 훈련 오차, 점선은 검증 오차입니다. 그림 1은 약 200회 학습한 기존 결과입니다. 그림 2와 그림 3은 약 100회 구간을 표시하였고, 최종 비교인 그림 4에서는 여섯 모델을 모두 100회 학습하였습니다. 그래프마다 실행 결과와 학습 구간이 다르므로 마지막 값을 서로 직접 비교하지 않고, 전체 비교는 그림 4를 기준으로 정리하였습니다.

4.1 기본 모델과 큰 모델

기본 모델의 파란 실선은 학습이 진행될수록 낮아졌습니다. 반면 파란 점선은 초반에 감소한 뒤 다시 높아졌습니다. 훈련 데이터에서는 오차가 줄어도 검증 데이터에서는 오차가 커져 과적합이 나타났습니다.

큰 모델의 초록 실선은 다른 모델보다 빠르게 0에 가까워졌고, 초록 점선은 학습 초반부터 크게 증가하였습니다. 은닉층의 뉴런을 512개로 늘렸지만 검증 결과는 좋아지지 않았습니다. 이번 결과에서는 모델을 크게 만드는 것보다 과적합을 줄이는 방법이 필요하였습니다.

교과목명	인공지능학습데이터전처리				
과제번호	2	학 번	2601110288	이 름	박수용
평가문항(수행내용)					

4.2 작은 모델

작은 모델의 주황 실선은 기본 모델과 큰 모델보다 높았지만, 주황 점선은 상대적으로 낮고 변화가 완만하였습니다. 후반에는 검증 오차가 조금씩 증가하였으므로 과적합이 완전히 사라진 것은 아닙니다. 그래도 모델 크기를 줄인 것이 과적합을 늦추는 데 도움이 되었습니다.

작은 모델은 훈련 오차가 더 높다는 이유만으로 과소적합이라고 볼 수는 없습니다. 그림 4에서도 작은 모델의 검증 오차가 낮았으므로, 모델 크기만으로 과소적합 여부를 판단하지 않았습니다.

5. L2와 Dropout 단독 적용 결과

L2와 Dropout을 각각 적용한 결과를 기존 모델과 비교하였습니다. 각 그래프의 가로축은 학습 회차, 세로축은 분류 오차이며 실선과 점선은 각각 훈련과 검증 결과입니다.

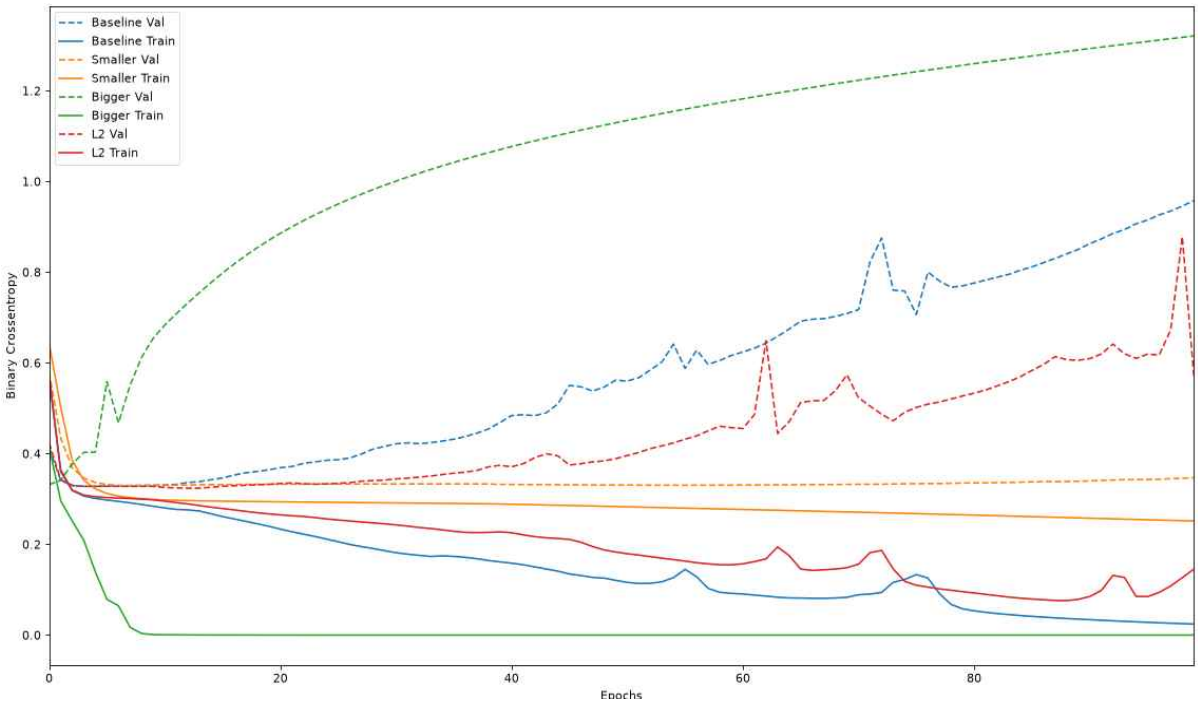


그림 2 기존 비교 모델에 L2 규제를 적용한 모델 추가

L2 모델은 기본 모델의 두 은닉층에 L2(0.001)를 적용한 모델입니다. 빨간 실선은 기본 모델의 훈련 오차보다 높았지만, 빨간 점선은 학습 후반에 기본 모델보다 대체로 낮았습니다. 큰 가중치를 억제한 것이 과적합을 줄이는 데 도움이 된 것으로 보았습니다. 다만 검증 오차가 다시 증가하고 중간에 값이 크게 변하여 과적합이 남아 있었습니다.

교과목명	인공지능학습데이터전처리				
과제번호	2	학 번	2601110288	이 름	박수용
평가문항(수행내용)					

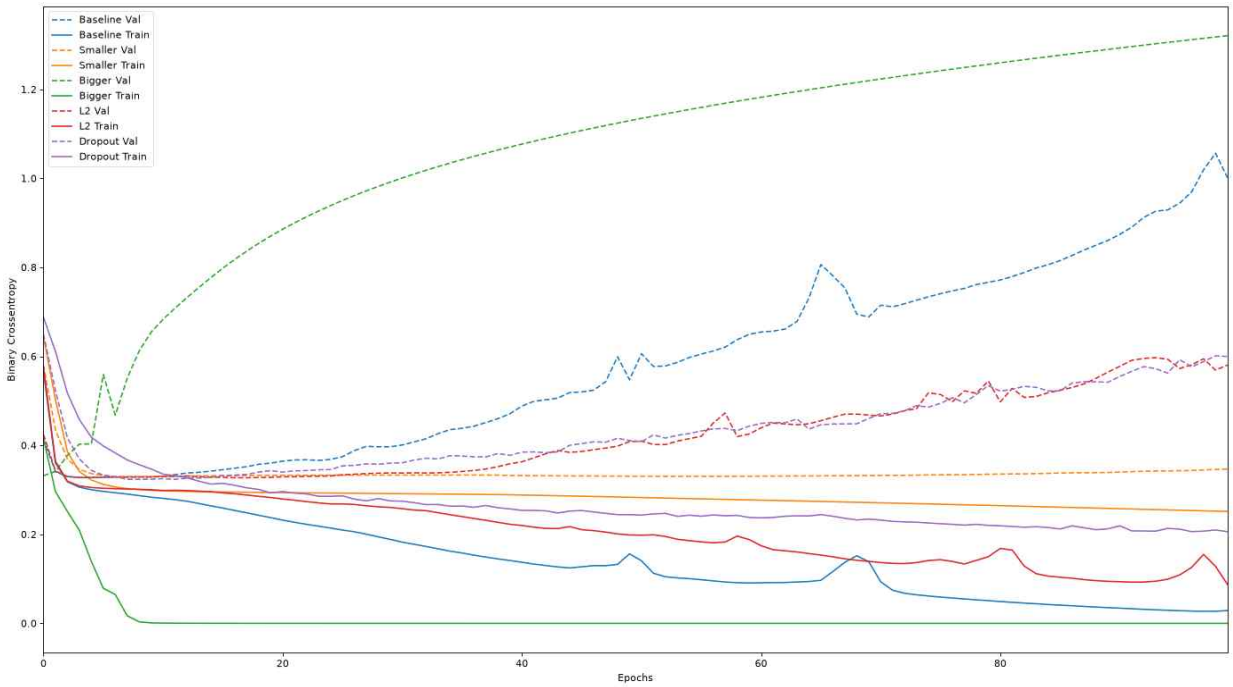


그림 3 기존 모델과 L2 및 Dropout 모델 비교

Dropout 모델은 각 은닉층 뒤에 Dropout(0.5)을 넣었습니다. 보라색 실선은 기본 모델보다 높았고, 보라색 점선은 학습 후반에 기본 모델보다 낮았습니다. Dropout도 과적합을 줄였지만 검증 오차는 점차 증가하였습니다. L2와 Dropout의 검증 곡선이 교차하는 구간도 있어, 한 방법이 항상 더 좋다고 결론 내리지는 않았습니다.

6. L2와 Dropout 동시 적용 결과

동시 적용 모델은 입력 1,000개 → Dense 16과 L2 → Dropout → Dense 16과 L2 → Dropout → sigmoid 출력 1개로 구성하였습니다. L2 계수는 0.001, Dropout 비율은 0.5입니다. 기존 다섯 모델과 함께 모두 100회, 배치 크기 512로 학습하였습니다.

교과목명	인공지능학습데이터전처리				
과제번호	2	학 번	2601110288	이 름	박수용

평가문항(수행내용)

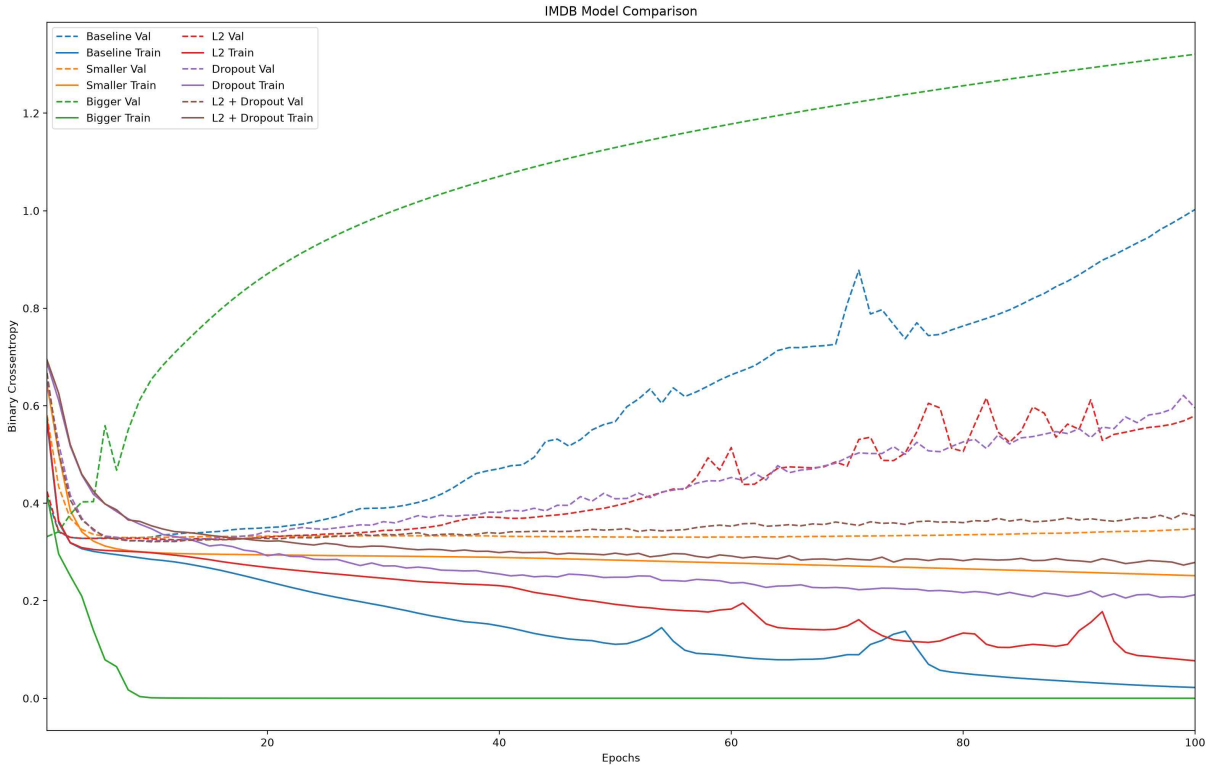


그림 4 여섯 모델의 100회 학습 결과 비교 실선은 훈련 점선은 검증

6.1 동시 적용의 효과

갈색 점선인 동시 적용 모델의 검증 오차는 초반에 감소한 뒤 후반에는 완만하게 증가하였습니다. 기본 모델과 큰 모델처럼 크게 증가하지 않았으며, 마지막 구간에서는 L2 단독과 Dropout 단독 모델보다 낮았습니다. 따라서 이번 실행에서는 두 방법을 함께 사용한 것이 후반의 과적합을 줄이는 데 도움이 되었습니다.

갈색 실선의 훈련 오차는 기본 모델보다 높았습니다. 규제가 훈련 데이터에 과하게 맞추는 것을 제한한 결과로 해석하였습니다. Dropout은 훈련 때만 적용되고 검증 때는 적용되지 않으므로, 두 오차의 차이에는 데이터 차이뿐 아니라 이 조건도 영향을 줍니다.

6.2 작은 모델과의 비교

학습 마지막 구간에서는 작은 모델의 주황 점선이 동시 적용 모델의 갈색 점선보다 조금 더 낮았습니다. 동시 적용 모델이 모든 비교 모델보다 우수한 것은 아니었습니다. 이번 결과에서는 규제 적용과 함께 모델 크기를 줄이는 방법도 효과가 있었으며, 최종 모델을 선택할 때는 검증 오차가 가장 낮아지는 회차를 함께 살펴보아야 합니다.

교과목명	인공지능학습데이터전처리				
과제번호	2	학 번	2601110288	이 름	박수용
평가문항(수행내용)					

7. 결과 정리와 결론

모델	그림 4에서 확인한 결과	해석
기본 모델	훈련 오차는 감소하고 검증 오차는 증가	장기 학습에서 과적합 발생
작은 모델	검증 오차가 낮고 후반 증가가 완만함	과적합이 늦어졌으나 완전히 없어지지는 않음
큰 모델	훈련 오차가 빠르게 0에 접근하고 검증 오차는 크게 증가	모델 용량 증가만으로 성능 개선은 어려움
L2 모델	후반 검증 오차가 기본 모델보다 낮으나 증가 추세는 남음	가중치 규제로 과적합 일부 완화
Dropout 모델	후반 검증 오차가 기본 모델보다 낮으나 증가 추세는 남음	뉴런 의존도를 줄여 과적합 일부 완화
L2와 Dropout 모델	후반 검증 오차가 단독 규제보다 낮으며 완만하게 증가	이번 실행에서 동시 적용의 과적합 완화 효과 확인

L2와 Dropout을 함께 적용한 모델은 기본 모델과 단독 규제 모델보다 후반 검증 오차가 낮았습니다. 다만 작은 모델의 마지막 검증 오차가 더 낮았고, 동시 적용 모델도 후반에는 오차가 조금씩 증가하였습니다. 규제뿐 아니라 모델 크기와 학습 횟수도 함께 조절해야 한다고 판단하였습니다.